

可解释谣言检测系统

基于 RoBERTa-large 分类与 DeepSeek-V3.2 解释的端到端框架

韩宇飞、姜新晨、靳卓达
上海交通大学计算机学院
第六组
hanyufei24@sjtu.edu.cn

任务目标

本大作业构建**可解释的谣言检测系统**：输入推文及事件 ID，输出二分类标签（谣言/非谣言）与判断依据的自然语言解释。数据集为英文推文，涵盖 7 个事件，训练集 2840 条，验证集 401 条。

具体内容

实施方案

系统采用**深度学习分类器 + 大语言模型解释器**的复合架构：




Fig. 1. 验证集混淆矩阵（401 条）

分类器：RoBERTa-large (355M) 微调，验证集准确率 89.53%。事件信息经 Embedding 层（7×32 维）与文本 [CLS] 拼接，避免传统 [EVENT_N] token 与文本词的不必要交互。

关键词提取：末层多头注意力 [CLS] 分数平均后取 Top-5 词，作为判断线索。

案例检索：sentence-transformers 检索训练集中 Top-3 相似案例，供 LLM 参考。

LLM 解释：通过 SJTU API 调用 DeepSeek-V3.2，将文本、分类结果、关键词、相似案例、事件背景组装为 Prompt，生成中文解释。LLM 定位为透明解释者而非独立法官——实验表明独立法官会使准确率从 89% 降至 65%。

置信度分级：确信 (≥ 0.9)、倾向 (0.7–0.9)、存疑 (< 0.7) 三级，助用户识别不确定场景，低置信度样本输出复核提醒。

核心代码分析

系统采用模块化设计：

models/classifier.py: RumorClassifier 基于 Hugging-Face AutoModel，支持 BERT/RoBERTa 系列。Event Embedding 与旧 token 模式兼容，load_model() 统一加载。

models/keyword_extractor.py: predict() 输出 {label, confidence, keywords}，兼容 BERT 与 RoBERTa 的 subword 合并。

llm_explainer.py: LLMExplainer 封装 OpenAI 兼容 API 调用，含五要素 Prompt 构建与重试机制。

inference.py: 端到端推理入口，-no-llm 约 4 分钟，完整模式约 39 分钟（API 限速）。

adversarial.py: 一键对抗攻防评估，-mode compare 完成样本生成 → 推理 → 翻转率对比。

检测结果分析

1) 模型训练与超参搜索

在 4×3090 GPU 上完成 15 组实验，搜索 BERT-base、RoBERTa-base、RoBERTa-large 三种架构：

TABLE I
最终模型在验证集（401 条）上的完整表现

指标	数值
Accuracy	89.53% (359/401)
Precision	90.30%
Recall	85.14%
F1 Score	87.65%
FP (误报)	16 (4.0%)
FN (漏报)	26 (6.5%)




Fig. 2. 各事件准确率与 F1 对比

关键发现: (1) 模型规模是最强杠杆, RoBERTa-large > RoBERTa-base > BERT-base, 较基线提升 +6.74%; (2) 大模型用小学习率, 小模型反之; (3) max_len=128 稳定优于 64; (4) Event 1 (Ferguson, 109 条) recall 仅 50%, 该事件争议大、真假难辨。

2) 三模型训练

为评估鲁棒性, 以 lr=1e-5、max_len=128、bs=16、dropout=0.2、seed=42 训练三个 RoBERTa-large 变体:

干净模型: 正常微调 10 epoch, 最佳 epoch 9, 准确率 89.53%。

对抗 V1: 每 5 步注入 WordNet 同义词替换 (max_swaps=2), 对抗与原始损失 0.5:0.5 加权, 最佳 epoch 5, 准确率 88.28%。

对抗 V2: 三种攻击随机混合 (同义词替换、随机删词、字符交换), 每 2 步注入, 对抗权重 1.0, 最佳 epoch 7, 准确率 89.53%——鲁棒性增强同时保持原准确率。




Fig. 3. 三级置信度准确率与占比

3) 置信度分级分析

TABLE II
三级置信度的准确率分布

分级	样本数	正确数	准确率
确信 (≥ 0.9)	245	230	93.9%
倾向 ($0.7-0.9$)	112	85	75.9%
存疑 (< 0.7)	44	24	54.5%

确信级准确率 93.9%, 表明模型高度自信时非常可靠; 存疑级 54.5% 接近随机, 说明模型知道何时不确定。

4) 对抗鲁棒性

在三个种子 (42/123/2026) 上用 WordNet 同义词替换 (max_swaps=2) 验证三模型鲁棒性:

TABLE III
三模型多种子对抗鲁棒性对比

模型	干净 Acc	平均翻转率	高置信翻转
clean (干净训练)	89.28%	6.4%	14.3
adv_v1 (同义词对抗)	88.03%	5.6%	7.0
adv_v2 (多攻击对抗)	88.28%	5.7%	9.3

对抗训练将翻转率平均降低 0.8%, 高置信翻转减半。V2 综合最优: 干净准确率仅降 1%, 多攻击防御均衡。

判断依据的可解释性分析

系统通过三个层次提供可解释性:

关键词提取: 末层所有注意力头 [CLS] 对 token 的平均关注度排序, 输出 Top-5 判别词。

案例检索: 训练集中检索 3 条最相似推文及标签, 为 LLM 提供参考锚点。

LLM 解释: 综合五要素生成中文解释, 低置信度时明确给出复核提醒。Prompt 经四轮迭代: 初始生硬, 尝试独立法官后准确率崩溃至 64.75%, 最终回滚为透明解释者。

工作总结

小组分工

韩宇飞负责系统集成与端到端推理管道、评估脚本与图表生成、对抗攻防骨架搭建与服务器端训练、LLM 速率调优与鲁棒性修复、README 文档与最终报告撰写; 姜新晨负责数据预处理、BERT/RoBERTa 分类器训练与关键词提取, 以及对抗样本攻防实验; 靳卓达负责 LLM 提示词工程、相似案例检索、解释生成模块, 以及置信度分级与 Event Embedding 升级。

收获与心得

通过本项目实践了从数据预处理、超参搜索到对抗评估的完整深度学习 pipeline。主要收获: (1) 模型规模是谣言检测的最强杠杆, 但需匹配学习率策略; (2) LLM 作为解释者优于独立法官——后者会引入与标注标准不一致的偏差; (3) 对抗训练有效降低高置信度攻击风险; (4) 置信度分级让系统具备“自知之明”。

遇到的问题及解决

API 速率限制: SJTU API 限 10 RPM, 401 条需 39 分钟。经 6 组压测确定 2 线程 +6s 间隔 (10.3 RPM 零失败), 并提供 -limit 快速验证。

LLM 角色: 独立法官角色使准确率从 89% 降至 65%, 因 LLM 常识与标注标准存在系统偏差。回退为透明解释者后解决了该问题。

Event 1 瓶颈: Ferguson 事件 recall 仅 50%, 即使升级 Event Embedding 改善仍有限, 反映跨事件泛化的根本挑战。

编码兼容: Unicode 特殊字符替换为 ASCII, 避免 Windows GBK 报错。

课程建议

建议在课程初期布置小规模实验任务 (如文本分类 baseline), 让同学提前熟悉深度学习框架与训练流程, 为大作业打下基础。

致谢

感谢课程教师和助教的指导，感谢 SJTU 提供 API 平台支持。本项目代码已开源：https://github.com/pnnooy/AI_rumor_detection。